Konsolenbasiertes Arbeiten mit SQLite

Michael Derntl

Dieses Tutorial führt sie Schritt für Schritt in die Konsolen-basierte Verwendung und Abfrage einer SQLite Datenbank ein. Grundlegende Kenntnisse über relationale Datenbanken und SQL Abfragen werden vorausgesetzt.

Beispieldaten
Zum Nachvollziehen der folgenden Schritte benötigen sie einige Dateien:

- Komplettdatenbank: schokolade.db
 - Rohdaten im CSV-Format (basierend auf Chocolate Bar Ratings Datensatz)
 - company.csv: Alle Firmen, die Schokoladen herstellen mit den Spalten:
 - * id: eindeutige Identifikationsnummer der Firma
 - * name: Name der Firma
 - * country: Land der Firma
 - <u>review.csv</u>: Alle Schokoladen-Reviews mit folgenden Spalten:
 - * id: eindeutige Identifikationsnummer des Reviews
 - * company_id: Identifikationsnummer der Firma (Verweis auf die id in der Tabelle company), die diese Schokolade hergestellt hat
 - * bar_name: Name des Schokoriegels
 - * year: Jahr des Reviews
 - * coca_pct: Kakaoanteil zwischen 0 und 1
 - * rating: Bewertung zwischen 1 und 5
 - * bean_type: Kakaobohnen-Sorte (fehlt bei vielen Einträgen)
 - * bean_origin: Kakaobohnen-Herkunft (fehlt bei vielen Einträgen)
 - $\bullet \ \ Datenbank definition: \ create_tables.sql$

SQLite Installation

sudo apt install sqlite3

SQLite unter Windows

https://sqlite.org/download.html

Für Windows am besten sqlite-tools-win32-x86-xxx.zip. Entpacken in ein beliebiges Verzeichnis. Dieses Verzeichnis dann zur Windows-Umgebungsvariable "Path" hinzufügen (Wie geht das?)

Ausprobieren

```
sqlite3 --version
```

Sollte mindestens 3.30 sein.

SQLite Konsole

Nun starten wir SQLite Konsole mit einer Datenbank. Dafür einfach als Argument den Dateinamen (z.B. schokolade.db) der Datenbank übergeben:

```
sqlite3 schokolade.db
```

Wenn die Datenbankdatei bereits existiert, wird sie geöffnet. Ansonsten wird eine neue Datenbank in dieser Datei angelegt.

Nun sind wir in der SQLite Konsole, die Ausgabe sollte wie folgt aussehen:

```
SQLite version 3.37.2 2022-01-06 13:25:41 Enter ".help" for usage hints. sqlite>
```

Bei diesem Prompt kann man nun zwei Arten von Kommandos absetzen:

- SQL-Befehle zum Erzeugen der Tabellen, Erstellen von Abfragen, etc.
- "Dot-Kommandos", das sind spezielle Steuerbefehle, die mit einem Punkt (dot) beginnen und mit denen man Einstellungen ändern kann oder Daten importieren kann

Dot-Kommandos

Eine komplette Liste der Dot-Kommandos erhält man mit dem Kommando ".help" (hier nur eine Auswahl dargestellt):

```
sqlite> .help
.backup ?DB? FILE
                        Backup DB (default "main") to FILE
.cd DIRECTORY
                        Change the working directory to DIRECTORY
                        Show number of rows changed by SQL
.changes on off
                        Clone data into NEWDB from the existing database
.clone NEWDB
                        Render database content as SQL
.dump ?OBJECTS?
.echo on|off
                        Turn command echo on or off
.excel
                        Display the output of next command in spreadsheet
.exit ?CODE?
                        Exit this program with return-code CODE
.headers on off
                        Turn display of headers on or off
                        Show help text for PATTERN
.help ?-all? ?PATTERN?
                        Import data from FILE into TABLE
.import FILE TABLE
.limit ?LIMIT? ?VAL?
                        Display or change the value of an SQLITE LIMIT
.mode MODE ?TABLE?
                        Set output mode
                        Use STRING in place of NULL values
.nullvalue STRING
                        Output for the next SQL command only to FILE
.once ?OPTIONS? ?FILE?
.open ?OPTIONS? ?FILE?
                        Close existing database and reopen FILE
                        Exit this program
.quit
.read FILE
                        Read input from FILE
                        Show the CREATE statements matching PATTERN
.schema ?PATTERN?
.separator COL ?ROW?
                        Change the column and row separators
                        Run CMD ARGS... in a system shell
.shell CMD ARGS...
```

```
.show
                        Show the current values for various settings
.tables ?TABLE?
                       List names of tables matching LIKE pattern TABLE
                       Set minimum column widths for columnar output
.width NUM1 NUM2 ...
```

Detaillierte Erklärungen aller Kommandos gibt es unter https://sqlite.org/cli.html

Datenbanktabellen erzeugen

Das Kommando ".tables" zeigt uns, dass die Datenbank noch leer ist. Daher erzeugen wir mal die Tabellen "company" und "reviews".

Dafür gibt es zwei Möglichkeiten: entweder die Kommandos in die Konsole schreiben, oder die Kommandos in eine Datei (z.B. create tables.sql) speichern und diese mit ".read" ausführen:

```
sqlite> .read create_tables.sql
sqlite> .tables
company review
```

Daten aus CSV importieren

Die Tabellen sind nun angelegt aber leer. Man kann nun die Tabellen zeilenweise füllen mit dem SQL Kommando "insert into", wir wollen aber lieber die Tabellen aus den CSV-Dateien füttern. Dafür gibt es das Kommando ".import". Lassen wir uns mal die Hilfe zum Import anzeigen:

```
sqlite> .help import
.import FILE TABLE
                         Import data from FILE into TABLE
  Options:
    --ascii
                         Use \037 and \036 as column and row separators
                         Use , and \n as column and row separators
    --csv
                         Skip the first {\tt N} rows of input
    --skip N
                         "Verbose" - increase auxiliary output
   -υ
  Notes:
   * If TABLE does not exist, it is created. The first row of input
      determines the column names.
    * If neither --csv or --ascii are used, the input mode is derived
      from the ".mode" output mode
    * If FILE begins with "|" then it is a command that generates the
      input text.
```

Wir werden also die Option "--csv" verwenden, und die erste Zeile (Spaltennamen) mittels "--skip 1" übergehen. Wenn keine Fehlermeldung kommt, kann man davon ausgehen, dass alles funktioniert hat. Wir gucken trotzdem wie viele Zeilen in company eingetragen wurden:

```
sqlite> .import --csv --skip 1 company.csv company
sqlite> select count(*) from company;
418
```

Das gleiche noch mit den Reviews, und voila die Datenbank ist gefüllt und bereit für unsere Abfragen:

```
sqlite> .import --csv --skip 1 review.csv review
sqlite> select count(*) from review;
1795
```

Quiz Warum haben wir erst "company" und dann erst "review" gefüllt?

Antwort Da die Einträge in Spalte "company_id" in Tabelle "review" auf die id Daten in "company" verweisen.

Abfragen

Man kann nun Abfragen in SQL formulieren, die Ergebnisse werden entsprechend ausgegeben, z.B. Jahreszahl und Bewertung aller Reviews für Schokoladen aus Vietnam:

```
sqlite> select year, rating from review where bean_origin = "Vietnam";
2014|2.75
2017|3.5
2016|3.5
2016|3.25
2010|3.25
[... einige ausgeblendete Zeilen...]
2016|3.0
2016|4.0
2015|3.25
2015|3.25
2012|3.5
```

Wir sehen die Ausgabe ist ohne Spaltenüberschrift und das verwendete Trennzeichen ist die Pipe. Das kann man mit den Kommandos .headers und .separator ändern, z.B. mit Tabulator als Trennzeichen:

```
sqlite> .headers on
sqlite> .separator "\t"
sqlite> select year, rating from review where bean_origin = 'Vietnam';
year rating
2014 2.75
2017 3.5
2016 3.5
2016 3.25
2010 3.25
[... einige ausgeblendete Zeilen...]
2016 3.0
2016 4.0
2015 3.25
2015 3.25
2012 3.5
```

Modus

Das Format der Ausgabe von Abfrageergebnissen kann man unter anderem über das Kommando ".mode" voreinstellen. Der Standardmodus ist "list", man kann aber z.B. auch CSV oder als Tabelle ausgeben lassen:

box Tables using unicode box-drawing characters

csv Comma-separated values

column Output in columns. (See .width)

html HTML code

insert SQL insert statements for TABLE

json Results in a JSON array
line One value per line
list Values delimited by "|"
markdown Markdown table format
quote Escape answers as for SQL

table ASCII-art table
tabs Tab-separated values
tcl TCL list elements

Wollen wir beispielsweise ein Abfrageergebnis als CSV-Datei speichern, so stellen wir den Ausgabemodus auf "csv" und verwenden das Kommando ".once" um die Ausgabe in eine Datei zu leiten:

```
sqlite> .once ergebnis.csv
sqlite> select year, rating from review where bean_origin = 'Vietnam';
```

Über Kommandozeile steuern

Um SQLite in einen Verarbeitungspipeline zu verwenden, kann man SQLite auch ohne interaktive Konsole verwenden:

```
> sqlite3 -help
```

Usage: sqlite3 [OPTIONS] FILENAME [SQL]

 ${\tt FILENAME} \ \, {\tt is} \ \, {\tt the} \ \, {\tt name} \ \, {\tt of} \ \, {\tt an} \ \, {\tt SQLite} \ \, {\tt database}. \ \, {\tt A} \ \, {\tt new} \ \, {\tt database} \ \, {\tt is} \ \, {\tt created}$

if the file does not previously exist.

OPTIONS include:

-A ARGS... run ".archive ARGS" and exit

-append append the database to the end of the file

-ascii set output mode to 'ascii'
-bail stop after hitting an error

-batch force batch I/O

-box set output mode to 'box'
-column set output mode to 'column'

-cmd COMMAND run "COMMAND" before reading stdin

-csv set output mode to 'csv'

-deserialize open the database using sqlite3_deserialize()

-echo print commands before execution

-init FILENAME read/process named file
-[no]header turn headers on or off
-help show this message

-html set output mode to HTML
-interactive force interactive I/O
-json set output mode to 'json'
-line set output mode to 'line'
-list set output mode to 'list'

-lookaside SIZE N use N entries of SZ bytes for lookaside memory

-markdown set output mode to 'markdown'

-maxsize N maximum size for a --deserialize database -memtrace trace all memory allocations and deallocations

-mmap N default mmap size set to N

```
-newline SEP
                     set output row separator. Default: '\n'
-nofollow
                     refuse to open symbolic links to database files
-nonce STRING
                     set the safe-mode escape nonce
                     set text string for NULL values. Default ''
-nullvalue TEXT
-pagecache SIZE N
                     use N slots of SZ bytes each for page cache memory
-quote
                     set output mode to 'quote'
                     open the database read-only
-readonly
                     enable safe-mode
-safe
-separator SEP
                     set output column separator. Default: '|'
                     memory stats before each finalize
-stats print
-table
                     set output mode to 'table'
                     set output mode to 'tabs'
-tabs
                     show SQLite version
-version
                     use NAME as the default VFS
-vfs NAME
                     open the file as a ZIP Archive
-zip
```

(Je nach verwendeter SQLite-Version können bei Ihnen weniger oder mehr als die hier gelisteten Optionen möglich sein.)

Nun wollen wir das Ergebnis unserer Vietnam-Abfrage direkt in der BASH ausgeben lassen (ohne interaktive SQLite-Konsole):

```
$ sqlite3 -csv -readonly schokolade.db \
"select year, rating from review where bean_origin = 'Vietnam'"
```

Beachten: das "\" am Zeilenende führt zum Ignorieren des Zeilenumbruchs, sodass der Befehl in der nächsten Zeile fortgeführt werden kann. (Aber nur, wenn nach dem "\" kein weiteres Leerzeichen etc. sondern direkt der Zeilenumbruch folgt!)

CSV | Datenbank | CSV

\$ head -n 10 review.csv

Nun wollen wir ein CSV-File in eine temporäre SQLite-Datenbank füttern und anschließend eine Abfrage machen, deren Ergebnis als CSV ausgegeben wird.

Gucken wir zunächst in die CSV-Datei review.csv, die ersten paar Zeilen sehen wie folgt aus:

```
id,company_id,bar_name,year,cocoa_pct,rating,bean_type,bean_origin
436,1,"Agua Grande",2016,0.63,3.75,,"Sao Tome"
437,1,Kpime,2015,0.7,2.75,,Togo
438,1,Atsane,2015,0.7,3.0,,Togo
439,1,Akata,2015,0.7,3.5,,Togo
440,1,Quilla,2015,0.7,3.5,,Peru
441,1,Carenero,2014,0.7,2.75,Criollo,Venezuela
442,1,Cuba,2014,0.7,3.5,,Cuba
443,1,"Sur del Lago",2014,0.7,3.5,Criollo,Venezuela
444,1,"Puerto Cabello",2014,0.7,3.75,Criollo,Venezuela
```

Jetzt pipen wir die komplette CSV-Datei in eine temporäre SQLite-Datenbank, führen die SQL Abfrage aus und gucken uns die ersten 10 Zeilen des Ergebnisses an:

```
$ cat review.csv | sqlite3 :memory: ".mode csv" ".import /dev/stdin review" \
"select year, rating from review where bean_origin = 'Vietnam'" | head -n 10
```

2014,2.75 2017,3.5

```
2016,3.5
2016,3.25
2010,3.25
2015,3.5
2015,2.75
2016,2.75
2016,3.0
2016,3.5
```

Um zu erklären, was bei obigen Aufruf von sqlite3 passiert, wird dieser im Folgenden nochmal in seine Teile zerlegt und diskutiert:

```
sqlite3 \
:memory: \
".mode csv" \
".import /dev/stdin review" \
"select year, rating from review where bean_origin = 'Vietnam'"
```

- :memory: ist ein spezieller "Dateiname" in SQLite, der andeutet, dass wir die Datenbank nicht in eine Datei auf den Datenträger speichern wollen, sondern mit einer temporären In-Memory-Datenbank arbeiten wollen, die so lange im Arbeitsspeicher existiert, wie das sqlite3 Kommando läuft.
- ".mode csv" müssen wir vor dem Import-Kommando verwenden, um CSV importieren zu können, und auch um CSV ausgeben zu lassen. Diese Notwendigkeit ergibt sich aus der Dokumentation: "Note that it is important to set the "mode" to "csv" before running the ".import" command. This is necessary to prevent the command-line shell from trying to interpret the input file text as some other format."
- ".import /dev/stdin review" veranlasst SQLite, von /dev/stdin zu lesen; das ist die Standardeingabe, also das was via cat review.csv an sqlite3 geliefert wird. Das CSV soll in die Tabelle review importiert werden.
- "select ..." ist die SQL-Abfrage, die wir ausführen wollen.

Um beispielsweise die Anzahl der Zeilen im Abfrageergebnis zu ermitteln, können wir den Output von sqlite3 zum Zeilenzählen an wc pipen, und sehen es gibt 38 Reviews von vietnamesischen Schokoladen:

```
$ cat review.csv | sqlite3 :memory: ".mode csv" ".import /dev/stdin review" \
"select * from review where bean_origin = 'Vietnam'" | wc -1
```

38